

《云计算与大数据处理》

实验报告

实验名称	数据湖与质量契约
实验日期	2026 年 10 月 27 日
专业	计算机科学与技术
班级	24 计科 3
学号	2410311319
姓名	彭博
指导教师	刘锦行

实验二 数据湖与质量契约实验报告

学号 2410311319，姓名 彭博，实验编号 02。这次我处理的是课程给出的合成服务事件。重点不是把文件转成 Parquet 就算结束，而是要说明原始行去了哪里、异常为什么被剔除，以及改变规则后结果如何变化。

一 实验目的

理解原始区、清洗区和汇总区的关系；用质量契约检查字段、时间、重复事件和 token 数；核对清洗前后数量守恒，并用一处明确的规则改动做正反验证。

二 实验原理

我把每条原始事件按事件编号、UTC 时间、数值范围等条件检查。合法且首次出现的事件进入 Silver；重复编号单独计数；不合格事件进入隔离记录。这样 20102 条原始记录应满足“有效唯一数＋重复数＋拒收数＝20102”。Silver 用 Parquet 保存，Gold 按 service 聚合，聚合结果还要用独立查询核对。

Parquet 体积变小主要来自列式存储和压缩。文件变小不代表数据质量自动变好，质量判断还是由字段校验、拒收原因和守恒式决定。SHA256 用于核对文件字节是否变化，不能证明数据来源本身可信。

三 实验环境与数据

Windows、本课程 Python 3.12 虚拟环境、coursekit、Parquet 与 DuckDB；输入为课程生成的合成事件，不含真实用户记录。基线运行 run_id 为 7f71ffbcaba248b39e970e7ae91639d1。

四 实验步骤与运行结果

1. 先运行 lab02 生成清洗结果。原始记录 20102 条，其中有效唯一 20000 条、重复 100 条、拒收 2 条；20102＝20000＋100＋2。两条拒收分别是负数 input_tokens 和无法解析的时间。原始文件 3892184 字节，Silver Parquet 为 224693 字节，单看这两个文件约缩小 94.2%。

2. 接着按 service 对照 Gold：assistant 14008 次、batch 2023 次、search 3969 次，总数恰好为 20000。三个服务的输入 token 合计 18015640，输出 token 合计 6145862；独立查询得到相同总量。这一步是为了避免清洗文件正确、汇总文件却漏行。

3. 在提供的质量规则脚本中，把 input_tokens 上限从 2000 调到 1200，并把原本测试用的布尔值改为字符串“100”，让负例仍然检验类型问题。改动后有效唯一 13405、重复 67、因上限被拒 6628，另有原始异常 2 条；13405＋67＋6628＋2 仍等于 20102。输入 token 合计降到 8110488。这个变化说明拒收规则确实被执行，并非只改了报告数字。

4. 最后重读 Silver manifest 并计算文件哈希。记录 source_sha256、silver_sha256 和 20000 行，确认基线文件与清单一致。个人规则变式只在独立脚本中运行，未拿它覆盖后续实验所需的共同 Silver 基线。

项目	基线	规则上限 1200
有效唯一	20000	13405
重复	100	67
拒收	2	6630
输入 token 合计	18015640	8110488

下图从课程自动生成的证据 HTML 页面保存。每张图顶部原生显示学号、实验编号和 run_id；同名 JSON、HTML 与完整截图均保存在本实验 evidence 目录。正文只摘录关键结果，详细字段以原始记录为准。

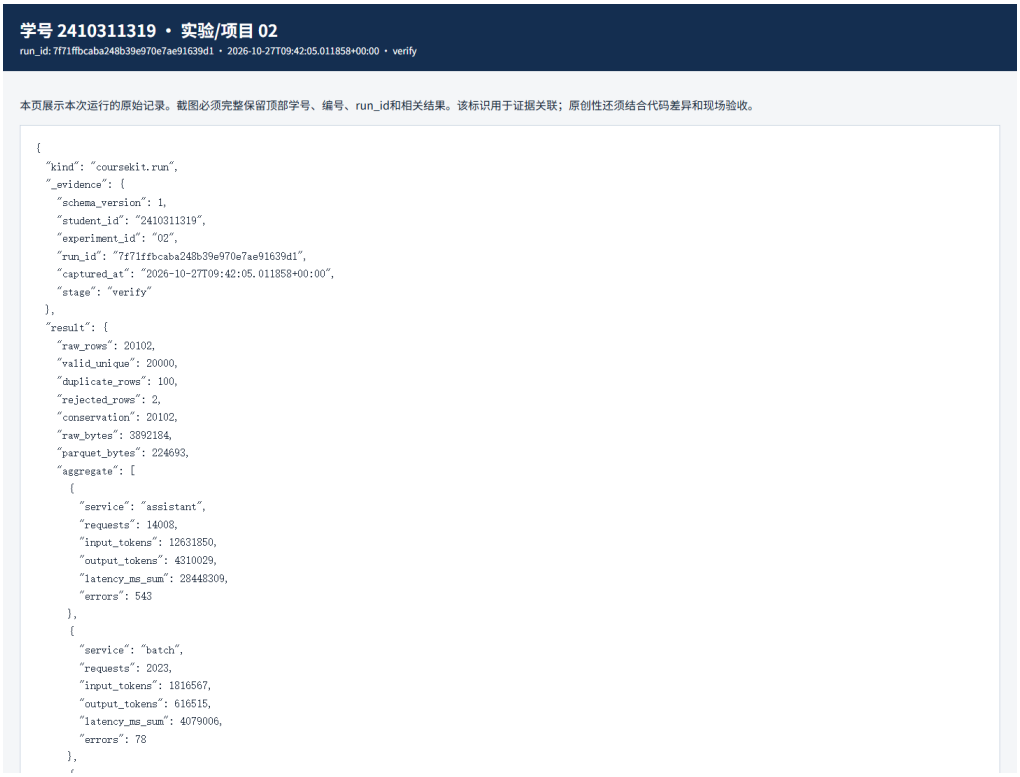


图 1 基线质量检查与数量守恒（run_id 7f71ffbcaba248b39e970e7ae91639d1）

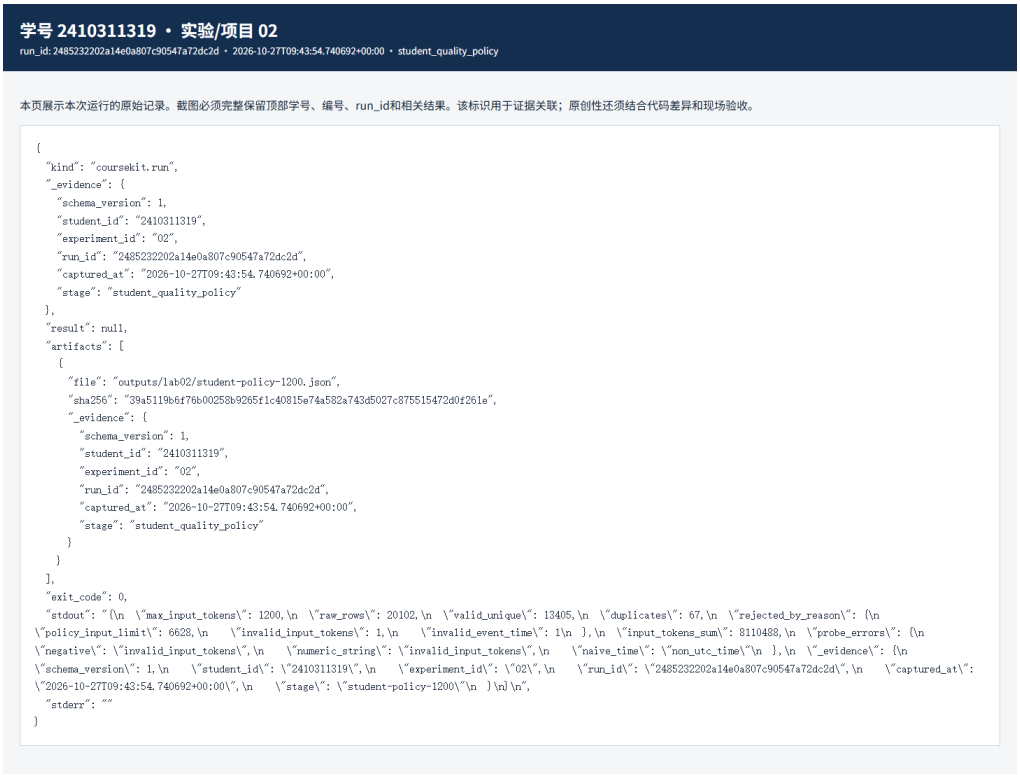


图 2 修改上限后的独立规则运行（run_id 2485232202a14e0a807c90547a72dc2d）

五 结果分析与讨论

上限降低后，有效行少了 6595 条，拒收数明显增加；重复数也从 100 变成 67，因为有些原本会被判成重复的记录先被新规则拒绝。由此可见，质量指标不仅取决于规则本身，还取决于校验顺序。不能把这组变式的数量直接说成原始数据“更脏”。

本次使用的是课程合成数据。守恒式、哈希和独立聚合能发现一部分处理错误，但它们不能单独说明字段定义是否符合真实业务，也不能取代源头授权和人工抽查。

六 思考题

1. 为什么要保留隔离记录？因为只留下 20000 条好数据会掩盖丢弃原因；记录行号和错误类型，后续才能复核规则是否过严。

2. 为什么不同上限下重复数也会变？去重只在通过前面检查的记录中发生，较早被拒收的行不会再计入后续重复。

七 实验总结

本次完成了从原始事件到 Silver、Gold 的检查，也验证了规则调整会怎样改变结果。最有用的不是某个压缩率，而是每一步都有可追的数量和原因。

八 资料与提交说明

课程资料：https://gitee.com/ryukinkou/BDP/。本实验仓库目录：https://github.com/Pb-Carl/-/tree/main/submissions/lab02。证据文件、局部代码改动和报告电子版放在该目录。

本报告使用 AI 助手协助整理文字、调整局部代码和执行验证；表中数值与截图来自所附本机原始运行记录。提交前仍需本人逐项理解并核对，教师复核另行进行。